

Файловые системы

АКОС, МФТИ

26 сентября, 2024



Встроенные

```
= STDIN_FILENO  
= STDOUT_FILENO  
= STDERR_FILENO
```

- **Потоки консоли:** ввод, вывод, ошибки;
- Почти всегда равны `0`, `1` и `2`
- Но лучше использовать константы;
- Их даже можно закрыть (но зачем?).

Пользовательские

```
= open(...)  
= socket(...)  
= accept(...)  
= epoll(...)  
= socketpair(...)*  
= signalfd(...), ...
```

- Файлы, сеть, мультиплексеры,...;
- Всё, что работает как поток данных.

Почему не `fopen(...)` ?

`fopen(...)` возвращает `FILE*`, а не дескриптор

Папки – тоже файлы?

```
1  int main() {
2      int fd = open("/", O_RDONLY, 0);
3      struct dirent ent = {};
4      while(getdents64(fd, &ent, sizeof(ent)) > 0) {
5          printf("%s\n", ent.d_name);
6          lseek(fd, ent.d_off, SEEK_SET);
7      }
8  }
```

Да, это тоже файловые дескрипторы. А ещё это директории, а не папки.

А если вызвать `read(...)` на директорию?

```
1  int main() {  
2      int fd = open("/", O_RDONLY, 0);  
3      char buffer[16];  
4      if(read(fd, buffer, sizeof(buffer)) >= 0) {  
5          printf("%15s", buffer);  
6      } else perror("read");  
7  }
```

Вывод: `read: Is a directory` . **Причина:** `read(...) == -EISDIR`

Файловый дескриптор - это

- **Число**, сопоставленное какому-то ресурсу.
- Его можно понимать, как **“указатель” на виртуальный класс**.
- **Разработчик должен помнить** типы дескрипторов. Это упрощают обёртки:
 - `FILE` , `fopen()` , `fclose()` , `fread()` , `fwrite()` , `fseek()` , ... для файлов;
 - `DIR` , `opendir()` , `closedir()` , `readdir()` , `seekdir()` , ... для директорий;
 - **И практически ничего** для работы с сокетами / сигналами / pipe-ами.
- Активные дескрипторы процесса можно увидеть в `/proc/<pid>/fd/`

```
open(char *path, int flags, mode_t mode)
```

Открыть (создать) файл (директорию).

int flags :

- |= **O_RDONLY** : Открыть на **чтение**;
- |= **O_WRONLY** : Открыть на **запись**;
- |= **O_RDWR** : Открыть на **чтение и запись**;
- |= **O_TRUNC** : **Очистить** файл при открытии;
- |= **O_CREAT** : **Создать** файл, если его нет;
- |= **O_EXCL** : Сломаться, если файл уже есть.

mode_t mode : маска прав для создаваемого файла.

Чтение и запись

- Для этого служат самые известные системные вызовы:

```
read(int fd, void* buf, size_t count)
```

```
write(int fd, void* buf, size_t count)
```

- Существуют `pread(...)` и `pwrite(...)`, которые **явно принимают позицию файла**.
- Если хочется одновременно записать **несколько буферов**, можно использовать:

```
readv(int fd, struct iovec *vector, int count)
```

```
writew(int fd, struct iovec *vector, int count)
```

```
lseek(int fd, off_t offset, int whence)
```

Настройка позиции файла

`int whence` :

- = `SEEK_SET` : Установить позицию на `offset` ;
- = `SEEK_CUR` : Сдвинуть позицию на `offset` ;
- = `SEEK_END` : Установить позицию в **конец** и сдвинуть на `offset` .

Узнать позицию можно системным вызовом `tell(int fd)`

`tell(int fd)`

Системный вызов управления дескрипторами.

`int cmd` :

- = `F_SETFD` : Установить флаги дескриптора;
- = `F_SETFL` : Установить флаги статуса;
- = `F_SETLK` : Установить **блокировку** на файл;
- = `F_DUPFD` : **Дублировать** дескриптор;
- = `F_SETSIG` : Получить сигнал, когда будет доступно чтение / запись;
- = `F_SETPIPE_SZ` : Настроить размер очереди.

`long arg` : аргумент, используется в `F_SET*` – командах

Какие флаги можно настраивать?

Флаги дескриптора (`F_SETFD`):

- `FD_CLOEXEC` : автоматически закрыть файл при вызове `exec()`
- И всё, их ровно одна штука 🧑.

Полезные флаги статуса (`F_SETFL`):

- `O_APPEND` : дописывать в конец файла, как в лог;
- `O_NONBLOCK` : запретить блокирующий ввод/вывод;
- `O_NOATIME` : не изменять время последнего доступа к файлу;

Бесполезные флаги статуса:

- `O_ASYNC` : получать сигнал по доступности чтения/записи;
- `O_DIRECT` : прямая запись, обход кеширования ядра;

А что такое файл?

Файл – это не путь!

```
/home/you/test.txt
```

Может быть тем же файлом, что и:

```
/home/you/test2.txt
```

Программа

```
write(fd, "Hi!", 4);
```

Дескриптор


Ядро

```
process->fds[fd]->inum
```

Номер inode

Диск

...



...

Index Node

- Структура, которую обычно называют “файлом”;
- Хранится в длинном массиве на жестком диске;
- **Знает**, где на жестком диске хранится **содержимое её файла**;
- **Хранит число ссылок** на саму себя (как `std::shared_ptr`).

/usr/bin/bash

Корень

Index
Node

Index
Node

Index
Node

Index
Node

Directory
Entries

.

..

etc

usr

...

.

..

bin

share

...

.

..

bash

mkdir

...

0x7f

0x45

0x4c


0x46

...

Directory Entry

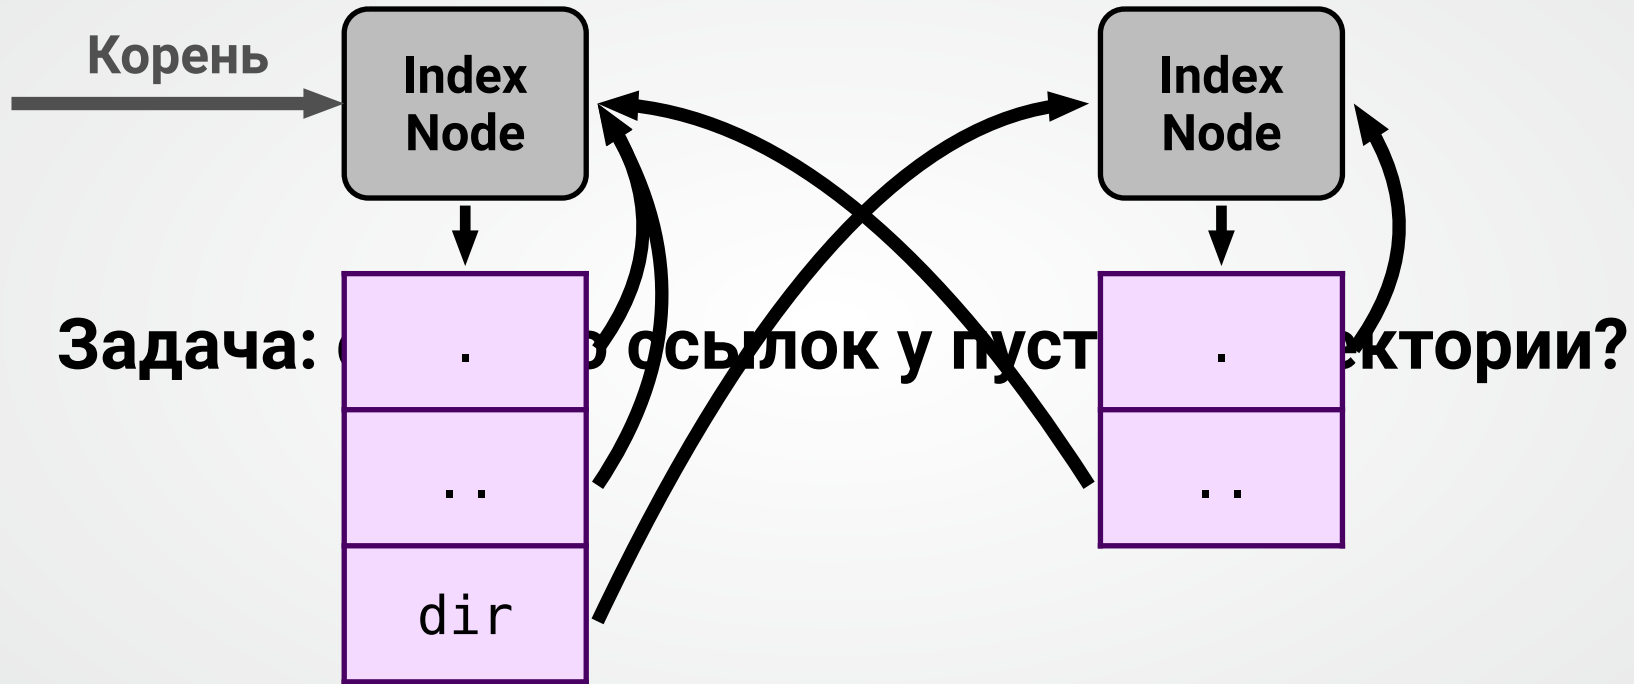
- Структура с **именем** и **адресом** Index Node;
- Может **ссылаться на свой же Index Node**(`./`);
- Живёт там, где обычно хранятся данные файла;
- Хранится в массиве других Directory Entry.

Что, если на Index Node несколько ссылок?



Это называется **жесткая ссылка**. Так можно только с файлами.

Задача: сколько ссылок у пустой директории?



Ответ: 2

VFS

Виртуальная файловая система

- К системе может быть подключено **много накопителей**: диски, USB-носители, ...;
- Каждый из них может иметь свою файловую систему;

Как работать со всем сразу?



VFS - Обобщённый интерфейс для ФС.

Можно думать об этом, как о виртуальном классе:

```
class ExFat: public virtual VFS { /* ... */ }
class Fat32: public virtual VFS { /* ... */ }
class NTFS:  public virtual VFS { /* ... */ }
class FAT:   public virtual VFS { /* ... */ }
class HFS:   public virtual VFS { /* ... */ }
// ...
```

Теперь любую из этих файловых систем можно подключить к системе:

```
void System::mount(VFS* filesystem, const char* path);
```



procfs – не файловая файловая система.

`$ cat /proc/meminfo` : информация о памяти;

`$ cat /proc/cpuinfo` : информация о CPU;

`$ cat /proc/version` : версия ядра;

`$ cat /proc/schedstat` : информация от планировщика о каждом CPU;

`$ cat /proc/filesystems` : информация о файловых системах.

`$ cat /proc/<pid>/schedstat` : информация от планировщика о процессе;

`$ ls /proc/<pid>/fd` : открытые файловые дескрипторы;

Эта файловая система тоже реализует интерфейс VFS.

Другие примеры

Системные:

`sysfs` : содержит информацию об устройствах и драйверах;

`pipefs` : служит для создания и использования pipe-ов;

`ramfs` : использует оперативную память вместо диска;


`tmpfs` : как `ramfs` , но со сбросом на swap;

Общего назначения:

`ecryptfs` : хранит файлы в зашифрованном виде;

`unionfs` : объединяет несколько файловых систем вместе;

`overlayfs` : хранит разницу двух файловых систем



Как быть, если очень хочется свою ФС?

FUSE

Filesystem in userspace

- +** Избавляет от необходимости разрабатывать драйвер для ядра;
- Работает медленнее, чем встроенные в ядро файловые системы.

**Ваша
программа**

```
graph TD; A[Ваша программа] --> B[Ядро]; B --> C[Драйвер ФС]; C --> B;
```

The diagram illustrates the flow of data and control between three components. At the top is a light blue rounded rectangle labeled 'Ваша программа' (Your program). Below it is a large light red rectangle labeled 'Ядро' (Kernel). Inside the 'Ядро' rectangle, on the right side, is a smaller light red rectangle labeled 'Драйвер ФС' (File System Driver). A black arrow points from the 'Ваша программа' box down to the 'Ядро' box. Another black arrow points from the 'Ядро' box to the 'Драйвер ФС' box. A third black arrow points from the 'Драйвер ФС' box back up to the 'Ядро' box. The background features a faint, stylized circuit board pattern.

Ядро


Драйвер ФС

**Ваша
программа**

**Userspace-
драйвер**

Ядро

Драйвер FUSE



Сеанс магии

И всё же, зачем?

- `$ sshfs` : проект сообщества, позволяет монтировать ФС через `$ ssh`
- Снижает поверхность атаки;
- Позволяет монтировать **почти любые образы дисков**, не имея прав администратора.



Спасибо за внимание!

 github.com/JakMobius/courses/tree/main/mipt-os-basic-2024